


PROPOSAL

KLASIFIKASI JENIS RETAKAN JALAN DENGAN *SUPPORT VECTOR MACHINE* DAN *GRADIENT BOOSTING DECISION TREE*



Anggota Kelompok:

Chelsea Christofera Antonioli Purnomo	25/558145/PA/23462
Ahmad Farhan Hidayat	25/559740/PA/23558
Muhammad Fahri Nur Sya'bani	25/561997/PA/23695
Saktyaveshavatar Dharmesthabuddhi	25/566653/PA/23920
Muhammad Gauza Faliha	25/555851/PA/23315

**PROGRAM STUDI S-1 ILMU KOMPUTER
JURUSAN ILMU KOMPUTER
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**

BAB 1

PENDAHULUAN

A. Latar Belakang

Infrastruktur jalan merupakan komponen fundamental dalam sistem transportasi darat yang berperan sentral dalam mendukung mobilitas masyarakat, distribusi barang dan jasa, serta pertumbuhan ekonomi wilayah karena fungsi jalan sebagai penghubung antardaerah memungkinkan arus logistik dan peningkatan aksesibilitas ke layanan publik secara lebih merata. Namun, seiring bertambahnya panjang dan konektivitas jaringan jalan, tantangan berupa kerusakan struktural dan fungsional tetap menjadi persoalan serius yang berdampak langsung pada keselamatan dan kenyamanan pengguna jalan. Berdasarkan data yang dirilis oleh Badan Pusat Statistik pada tahun 2021, sekitar 31,9% dari total panjang jalan di Indonesia, yang setara dengan 174.298 km, berada dalam kondisi rusak (Zain, 2024).

Apabila retakan pada perkerasan jalan tidak segera diidentifikasi dan ditangani, kerusakan tersebut cenderung meluas secara progresif seiring paparan beban lalu lintas berulang dan faktor cuaca sehingga mempercepat degradasi struktural jalan sebelum mencapai umur rencananya. Konsekuensinya, biaya pemeliharaan dan perbaikan yang harus ditanggung menjadi jauh lebih besar dibandingkan penanganan dini.

Selama ini, inspeksi kondisi retakan jalan secara konvensional masih banyak dilakukan melalui pengamatan visual langsung oleh petugas di lapangan. Pendekatan ini, sebagaimana dikemukakan oleh Sari, Prakoso, dan Baskara (2019), memerlukan biaya pemeliharaan yang besar, menyita banyak tenaga dan waktu, serta bersifat subjektif karena sangat bergantung pada penilaian individual masing-masing petugas survei. Keterbatasan tersebut mendorong berkembangnya pendekatan otomatis berbasis pengolahan citra digital yang memungkinkan proses identifikasi dan klasifikasi retakan dilakukan secara lebih konsisten, objektif, dan efisien.

Meskipun *deep learning* kini banyak digunakan untuk tugas klasifikasi citra, pendekatan berbasis ekstraksi fitur tangan dengan *machine learning* klasik seperti SVM dan XGBoost masih relevan digunakan, khususnya pada skenario dengan keterbatasan data berlabel atau sumber daya komputasi, sekaligus menawarkan interpretabilitas fitur

yang lebih baik dibandingkan model *deep learning* yang bersifat *black-box*. Namun, keberhasilan klasifikasi dipengaruhi oleh karakteristik visual citra yang digunakan. Perbedaan tekstur permukaan perkerasan, pencahayaan, skala retakan, serta kondisi akuisisi dapat menghasilkan variasi distribusi visual yang memengaruhi proses segmentasi dan ekstraksi fitur. Selain itu, penggunaan satu sumber dataset berpotensi menyebabkan representasi fitur terlalu menyesuaikan karakteristik spesifik *dataset* tersebut sehingga kemampuan metode dalam menghadapi variasi citra dari sumber lain belum dapat diketahui. Oleh karena itu, penggunaan beberapa sumber data dengan karakteristik yang saling melengkapi menjadi penting untuk memperluas keragaman visual dan mengevaluasi konsistensi metode klasifikasi pada kondisi data yang berbeda.

Penelitian ini memanfaatkan dua sumber *dataset*, yaitu PaveBench dan *pavement cracks computer vision dataset* dari Roboflow. PaveBench merupakan *benchmark* citra perkerasan jalan dunia nyata yang mempertahankan kasus *hard distractor* yang menantang secara visual (Li et al., 2026). Sementara itu, dataset Roboflow yang digunakan merupakan dataset yang terdiri atas berbagai jenis kerusakan jalan, termasuk *alligator cracking*, *longitudinal cracking*, dan *transverse cracking*. Dengan memanfaatkan kedua sumber dataset tersebut, penelitian ini mengembangkan *pipeline* klasifikasi jenis retakan jalan yang terdiri atas peningkatan kualitas citra, segmentasi, ekstraksi fitur tekstur, orientasi, dan morfologi-topologi, serta klasifikasi menggunakan Support Vector Machine dan Extreme Gradient Boosting. *Pipeline* tersebut dievaluasi untuk mengetahui kemampuan representasi fitur yang diusulkan dalam membedakan *alligator cracking*, *longitudinal cracking*, dan *transverse cracking* pada data dari lebih dari satu sumber.

B. Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah dalam penelitian ini adalah sebagai berikut.

1. Bagaimana penerapan tahapan peningkatan kualitas citra dan segmentasi dalam mengekstraksi struktur retakan dari citra jalan yang berasal dari dua sumber dataset dengan karakteristik visual yang berbeda?

2. Bagaimana kombinasi fitur tekstur, orientasi, dan morfologi-topologi sebagai representasi karakteristik pembeda antara *alligator cracking*, *longitudinal cracking*, dan *transverse cracking*?
3. Bagaimana perbandingan performa algoritma Support Vector Machine (SVM) dan Extreme Gradient Boosting (XGBoost) dalam mengklasifikasikan jenis retakan jalan berdasarkan representasi fitur yang diusulkan?
4. Bagaimana perbandingan performa klasifikasi jenis retakan jalan menggunakan Support Vector Machine (SVM) dan Extreme Gradient Boosting (XGBoost) ketika model dilatih menggunakan dua sumber *dataset*, baik secara terpisah maupun digabungkan?

C. Batasan

Adapun batasan dalam penelitian ini adalah sebagai berikut.

1. Penelitian ini hanya mengklasifikasikan tiga jenis retakan jalan, yakni *alligator cracking*, *longitudinal cracking*, dan *transverse cracking* agar relevan dengan ketersediaan kelas dalam dua *dataset*.
2. Hasil klasifikasi hanya diuji pada metrik *F1 Score*, tidak termasuk kecepatan inferensi.
3. *Dataset* kedua memiliki jumlah citra yang relatif lebih sedikit dibandingkan dengan *dataset* pertama, dengan selisih sekitar 6.500 citra.

D. Tujuan

Berdasarkan rumusan masalah tersebut, tujuan dari penelitian ini adalah sebagai berikut.

1. Menerapkan tahapan peningkatan kualitas citra dan segmentasi untuk mengekstraksi struktur retakan dari citra jalan yang berasal dari dua sumber *dataset*.
2. Mengekstraksi dan mengintegrasikan fitur tekstur, orientasi, dan morfologi-topologi ke dalam satu representasi vektor fitur untuk membedakan *alligator cracking*, *longitudinal cracking*, dan *transverse cracking*.

3. Membandingkan performa SVM dan XGBoost dalam mengklasifikasikan jenis retakan jalan pada skenario penggunaan dua sumber *dataset* secara terpisah dan penggabungan kedua sumber *dataset* berdasarkan Macro F1 Score.

E. Manfaat

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut.

Manfaat Teoritis :

1. Menjadi dasar atau pijakan bagi penelitian selanjutnya yang ingin mengembangkan metode klasifikasi retakan jalan, baik menggunakan pendekatan serupa maupun *deep learning*.
2. Memperkaya kajian ilmiah mengenai efektivitas kombinasi fitur sebagai representasi komplementer dalam menangkap karakteristik tekstur, orientasi garis, dan topologi retakan, sehingga dapat menjadi rujukan pengembangan deskriptor fitur berbasis *handcrafted feature* pada bidang pengolahan citra digital lainnya.
3. Memberikan kontribusi empiris terhadap perbandingan performa algoritma klasifikasi berbasis margin Support Vector Machine (SVM) dan berbasis *ensemble* pohon (*Extreme Gradient Boosting*) pada representasi fitur multimoda sehingga memperkaya literatur mengenai pemilihan algoritma *machine learning* klasik untuk kasus klasifikasi citra dengan kelas yang memiliki kemiripan visual tinggi.

Manfaat Praktis :

1. Membantu instansi pengelola infrastruktur jalan (seperti Dinas Pekerjaan Umum dan Perumahan Rakyat/Bina Marga) dalam melakukan identifikasi jenis retakan jalan secara lebih cepat, konsisten, dan objektif dibandingkan inspeksi visual manual, sehingga mendukung efisiensi biaya dan waktu survei serta pengambilan keputusan prioritas pemeliharaan yang lebih tepat sasaran.
2. Menjadi landasan teknis bagi pengembangan sistem atau aplikasi pemantauan kondisi jalan berbasis citra digital yang dapat diintegrasikan dengan kendaraan inspeksi atau kamera jalan di lapangan.
3. Menawarkan solusi klasifikasi yang ringan secara komputasi dan tidak bergantung pada sumber daya GPU besar seperti pada *deep learning*, sehingga lebih mudah

diimplementasikan pada perangkat dengan spesifikasi terbatas di lapangan (misalnya laptop petugas survei atau sistem *embedded* pada kendaraan inspeksi jalan).

BAB 2

KAJIAN PUSTAKA

A. Jenis Keretakan Jalan

Keretakan pada jalan beraspal dapat diklasifikasikan ke dalam beberapa jenis berdasarkan pola visual, arah orientasi, dan mekanisme kegagalan strukturalnya sebagai berikut.

1. *Alligator Cracking*

Alligator cracking memiliki pola jaring yang saling terhubung dan menyerupai kulit buaya. Jenis retakan ini dapat disebabkan kelelahan struktural dan beban lalu lintas dalam frekuensi tinggi yang berulang (Ha et al., 2022).

2. *Longitudinal Cracking*

Longitudinal cracking merupakan retakan yang memanjang sejajar bahu jalan atau lajur (Ha et al., 2022). Beban roda yang terlalu berat dapat menekan aspal sehingga *longitudinal cracking* dapat terbentuk (Liang et al., 2025).

3. *Transverse Cracking*

Transverse cracking merupakan retakan yang melintang tegak lurus sumbu jalan. Retakan ini disebabkan oleh penyusutan termal yang dipengaruhi oleh faktor suhu (Ha et al., 2022).

B. Pengolahan Citra Digital untuk Analisis Keretakan Jalan

Inspeksi kondisi retakan pada perkerasan jalan secara konvensional dilakukan melalui pengamatan visual oleh petugas di lapangan, sebuah pendekatan yang menurut Sari, Prakoso, dan Baskara (2019) memerlukan biaya pemeliharaan yang besar, membutuhkan banyak tenaga dan waktu, serta bersifat subjektif karena bergantung pada penilaian individual tiap petugas survei. Keterbatasan tersebut mendorong berkembangnya pendekatan otomatis berbasis pengolahan citra digital, yang memungkinkan proses identifikasi retakan dilakukan secara lebih konsisten dan efisien melalui analisis karakteristik visual retakan yang terekam dalam citra digital, tanpa harus sepenuhnya bergantung pada interpretasi manual di lapangan.

Retakan pada perkerasan jalan memiliki sejumlah karakteristik visual yang dapat melalui pengolahan citra digital. Hu, Zhao, dan Wang (2010) memandang bahwa retakan muncul sebagai inhomogenitas atau penyimpangan pola tekstur dari permukaan aspal di sekitarnya. Selain karakteristik tekstur tersebut, retakan juga dicirikan oleh perbedaan intensitas atau kontras warna terhadap latar belakang yang umumnya tampak lebih gelap dibandingkan permukaan aspal yang mengelilinginya. Selain itu, karakteristik lain yang dapat dianalisis adalah orientasi garis dan pola konektivitas retakan. Retakan longitudinal dan transversal cenderung memiliki orientasi dominan yang jelas (mendekati 90 derajat dan 0 derajat secara berurutan) serta jumlah objek retakan yang sedikit, sementara retakan tipe *alligator* dicirikan oleh jumlah objek yang banyak dengan sebaran orientasi yang jauh lebih acak akibat pola retakan yang saling terhubung membentuk jaring. Karakteristik ini tekstur, kontras, orientasi garis, dan pola konektivitas menjadi dasar bagi berbagai teknik pengolahan citra digital untuk mengidentifikasi dan membedakan retakan dari latar belakangnya.

Meskipun kemudian, ekstraksi fitur dari citra jalan menghadapi sejumlah permasalahan teknis. Tekstur latar belakang yang kompleks dan kondisi pencahayaan yang tidak merata dapat menyebabkan proses deteksi tepi konvensional menghasilkan banyak deteksi keliru, terutama ketika ambang batas segmentasi ditentukan secara global. Selain itu, derau yang berasal dari tekstur kasar aspal dapat memperbesar risiko kesalahan ini. Di sisi lain, retakan pada umumnya berbentuk struktur yang tipis dan memanjang sehingga proporsinya terhadap keseluruhan citra sangat kecil. Chen et al. (2022) menunjukkan bahwa apabila informasi arah tidak ditangani secara khusus, informasi mengenai orientasi retakan yang krusial untuk membedakan jenisnya berisiko hilang atau tidak terwakili secara memadai dalam deskriptor fitur yang dihasilkan.

Berbagai teknik pengolahan citra digital telah dikembangkan untuk mengatasi permasalahan tersebut sekaligus mengekstraksi karakteristik retakan secara efektif. Untuk menganalisis karakteristik tekstur, digunakan deskriptor statistik seperti *Gray-Level Co-occurrence Matrix* yang menangkap hubungan spasial antarpiksel pada berbagai arah sudut. Selain itu, terdapat *Local Binary Pattern* yang menangkap pola mikro atau tekstur lokal di sekitar tiap piksel. Untuk mengatasi permasalahan kontras rendah dan derau tekstur sebelum karakteristik tersebut diekstraksi, diterapkan teknik peningkatan kualitas

citra seperti ekualisasi histogram adaptif dan operasi morfologi berbasis *top-hat* atau *bottom-hat* transform. Selanjutnya, terdapat teknik *thresholding* otomatis seperti metode Otsu untuk memisahkan piksel retakan dari latar belakang berdasarkan distribusi intensitasnya. Adapun untuk menangkap karakteristik orientasi garis dan pola konektivitas, digunakan teknik analisis komponen terhubung (*connected component analysis*) untuk mengukur jumlah dan tingkat interkoneksi objek retakan hasil segmentasi. Kombinasi teknik-teknik tersebut menjadi dasar bagi berbagai penelitian terdahulu dalam mengembangkan sistem klasifikasi retakan jalan berbasis pengolahan citra digital dan pembelajaran mesin.

C. Penelitian Terdahulu yang Relevan

Penelitian mengenai deteksi dan klasifikasi retakan jalan menggunakan pendekatan pengolahan citra digital dan pembelajaran mesin klasik telah dikembangkan secara berkelanjutan. Pada konteks jalan di Indonesia, Sari, Prakoso, dan Baskara (2019) mengumpulkan citra jalan di Banjarmasin menggunakan kamera telepon pintar dan menerapkan segmentasi Otsu untuk memperoleh area retakan secara kasar, dilanjutkan ekstraksi fitur GLCM pada empat arah sudut dan mengklasifikasikannya ke dalam kategori retak atau tidak retak menggunakan SVM dengan lima jenis kernel yang dibandingkan. Selain itu, penelitian oleh Chen, Seo, Jun, dan Zhao (2022) secara spesifik menyasar klasifikasi jenis retakan dari 12 ribu citra jalan di Suzhou, Tiongkok ke dalam tiga kategori, yaitu *transverse crack*, *longitudinal crack*, dan *alligator crack*. Fitur yang diekstraksi adalah Local Binary Pattern yang dipecah ke dalam sembilan spasial untuk menangkap informasi arah retakan secara lebih rinci, kemudian direduksi dimensinya menggunakan *Principal Component Analysis* sebelum diklasifikasikan dengan SVM.

Selanjutnya, terdapat penelitian oleh Hoang dan Nguyen (2019) yang mengombinasikan fitur berbasis *steerable filter Gaussian*, integral proyektif, serta teknik peningkatan ambang Otsu bernama *min-max gray level discrimination* (M2GLD) untuk memperbaiki kualitas binerisasi sebelum fitur objek retakan diekstraksi. Penelitian tersebut membandingkan performa SVM, Artificial Neural Network, dan Random Forest menggunakan 200 citra jalan yang terbagi rata ke dalam empat kelas, yakni *no crack*, *longitudinal crack*, *transverse crack*, dan *alligator crack*.

Di sisi lain, penelitian Chatterjee, Chatterjee, Roy, dan Gourisaria (2022) mengusulkan *pipeline* ringan seleksi fitur menggunakan Genetic Algorithm, Particle Swarm Optimization, LASSO, serta Orthogonal Matching Pursuit, yang kemudian diklasifikasikan menggunakan Logistic Regression, k-Nearest Neighbors, Decision Tree, dan Extreme Gradient Boosting.

BAB 3

METODOLOGI

A. Akuisisi Data

Dataset yang digunakan dalam penelitian ini terdiri atas dua dataset. *Dataset* pertama merupakan citra jalan retak yang diperoleh dari PaveBench (Li, 2026) dan tersedia pada *platform* Hugging Face. Pada penelitian ini, digunakan subset klasifikasi, yaitu bagian *Distress_Classification*, yang telah disusun dalam struktur direktori berbasis kelas dan terbagi ke dalam tiga *subset* data, yaitu data latih, validasi, dan uji. Secara keseluruhan, *subset* ini memuat enam kelas, yaitu *alligator crack*, *longitudinal crack*, *transverse crack*, *patch*, *pothole*, dan *negative*. Karena proyek ini difokuskan pada klasifikasi jenis retakan jalan, hanya digunakan kelas yang relevan dengan ruang lingkup proyek, yaitu *alligator crack*, *longitudinal crack*, dan *transverse crack*, sedangkan kelas di luar cakupan tersebut tidak digunakan. Pembagian jumlah citra pada data latih, data validasi, dan data uji serta rincian distribusi jumlah citra pada setiap kelas untuk masing-masing subset data disajikan pada Tabel 1.

Dataset kedua yang digunakan dalam penelitian ini merupakan *Pavement Cracks Computer Vision Dataset* yang diperoleh melalui *platform* Roboflow Universe. Dataset tersebut telah terbagi ke dalam tiga *subset* data, yaitu data latih, validasi, dan uji. Dataset ini terdiri atas delapan kelas, yaitu *pothole*, *alligator cracking*, *edge cracking*, *longitudinal cracking*, *patching*, *pavement*, *rutting*, dan *transverse cracking*. Dalam penelitian ini, hanya digunakan tiga kelas yang relevan dengan ruang lingkup klasifikasi jenis retakan jalan, yaitu *alligator cracking*, *longitudinal cracking*, dan *transverse cracking*. Sementara itu, kelas lainnya tidak digunakan dalam proses penelitian. Pembagian jumlah citra pada data latih, data validasi, dan data uji serta rincian distribusi jumlah citra pada setiap kelas untuk masing-masing subset data disajikan pada Tabel 2.

Pembagian	<i>Alligator Crack</i>	<i>Longitudinal Crack</i>	<i>Transverse Crack</i>	Total
Data latih	1.672	3.060	2.456	7.188
Data validasi	209	381	308	898

Data uji	210	391	300	901
Total	2.091	3.832	3.064	8.987

Tabel 1. Rincian Distribusi Citra Dataset 1

Pembagian	<i>Alligator Crack</i>	<i>Longitudinal Crack</i>	<i>Transverse Crack</i>	Total
Data latih	405	596	651	1.652
Data validasi	135	136	159	430
Data uji	50	92	105	247
Total	590	824	915	2.329

Tabel 2. Rincian Distribusi Citra Dataset 2

B. Peningkatan Kualitas Citra

Untuk meningkatkan kualitas citra dan mempermudah ekstraksi fiturnya, dilakukan beberapa metode peningkatan kualitas citra. Sebelum itu, setiap citra dikonversi menjadi *grayscale* untuk menyederhanakan representasi citra menjadi satu kanal intensitas sehingga kanal warna yang tidak diperlukan untuk ekstraksi fitur retakan jalan tidak digunakan pada tahap-tahap selanjutnya. Selanjutnya, diterapkan tahapan peningkatan kualitas citra sebagai berikut.

1. *Gaussian Filtering*

Gaussian filtering bekerja dengan mengonvolusikan citra masukan dengan sebuah kernel yang nilai bobotnya mengikuti fungsi distribusi Gaussian dua dimensi. Fungsi kernel tersebut didefinisikan sebagai:

$$G(x, y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right) \quad (1)$$

dengan x dan y menyatakan koordinat piksel relatif terhadap pusat kernel dan σ menyatakan simpangan baku yang mengendalikan tingkat kehalusan *filtering*. Citra keluaran diperoleh melalui operasi konvolusi antara citra masukan $I(x, y)$ dan

kernel tersebut, dituliskan sebagai $I'(x, y) = I(x, y) * G(x, y)$. Filter ini diterapkan agar derau berfrekuensi tinggi yang berasal dari tekstur kasar permukaan jalan dapat diredam terlebih dahulu sehingga tidak menimbulkan deteksi tepi palsu yang dapat mengganggu proses segmentasi pada tahap berikutnya.

2. *Contrast Limited Adaptive Histogram Equalization (CLAHE)*

CLAHE bekerja dengan cara meningkatkan kontras lokal secara adaptif dan membatasi penguatan derau. Dalam penerapannya, citra terlebih dahulu dibagi ke dalam sejumlah wilayah kecil yang saling bertetangga. Selanjutnya, pada setiap wilayah tersebut, histogram intensitas pikselnya akan dihitung dan langsung dipotong menggunakan suatu nilai ambang batas. Puncak histogram yang melebihi ambang batas ini kemudian didistribusikan ulang secara merata ke seluruh rentang intensitas untuk mengendalikan kontras agar tidak berlebihan. Setelah proses redistribusi tersebut, fungsi transformasi intensitas piksel akan dihitung secara terpisah untuk setiap wilayah, didefinisikan sebagai:

$$s = T(r) = (L - 1) \sum_{k=0}^r p(k) \quad (2)$$

dengan r sebagai intensitas piksel masukan, s sebagai intensitas piksel keluaran, L menyatakan jumlah tingkat keabuan, dan $p(k)$ sebagai probabilitas kemunculan intensitas k pada histogram wilayah tersebut.

Penerapan CLAHE pada kasus ini didasari oleh sifat citra retakan jalan yang berpotensi memiliki variasi pencahayaan antarbagian, bahkan dalam satu bingkai citra tunggal, sebagai akibat dari sudut pengambilan maupun kondisi pencahayaan saat proses akuisisi berlangsung. Sifat adaptif pada CLAHE memungkinkan kontras antara piksel retakan dan piksel latar belakang aspal ditingkatkan secara lokal sesuai kondisi tiap wilayah citra dan mencegah penguatan derau secara berlebihan pada wilayah yang kontrasnya sudah relatif rendah.

3. *Black Bottom-Hat Transform*

Black bottom-hat transform merupakan operasi morfologi yang bertujuan menonjolkan struktur gelap berukuran kecil pada citra yang memiliki latar belakang

terang. Operasi ini didefinisikan sebagai selisih antara hasil operasi *closing* morfologi terhadap citra asli dengan citra asli itu sendiri, dituliskan sebagai:

$$B(I) = (I \bullet SE) - I \quad (3)$$

dengan I menyatakan citra masukan, E menyatakan elemen penstruktur (*structuring element*), dan operasi closing ($I \bullet SE$) didefinisikan sebagai dilasi yang dilanjutkan dengan erosi terhadap citra menggunakan elemen penstruktur yang sama, yaitu $(I \bullet SE) = (I \oplus SE) \ominus SE$.

Retakan pada citra jalan secara khas tampak sebagai struktur tipis dan memanjang yang intensitasnya lebih gelap dibandingkan permukaan aspal di sekitarnya sehingga karakteristik ini selaras dengan struktur yang ditonjolkan oleh *black bottom-hat transform*. Dengan diterapkannya *black bottom-hat transform*, intensitas piksel retakan menjadi jauh lebih menonjol relatif terhadap latar belakang sehingga tahap selanjutnya dapat dilakukan dengan lebih akurat.

C. Segmentasi Citra

Tahap segmentasi bertujuan untuk memisahkan struktur retakan dari latar belakang permukaan aspal. Tahapan ini menerima masukan berupa citra hasil peningkatan kualitas $I_{\text{enhanced}}(x, y)$ yang telah diproses. Untuk mengekstraksi struktur retakan secara utuh dan meminimalkan derau tepi sisa, diterapkan strategi fusi spasial yang mengombinasikan segmentasi berbasis intensitas, yakni *otsu thresholding*, dan segmentasi berbasis diskontinuitas gradien lokal, yakni *canny edge detection*.

1. Segmentasi Berbasis Ambang Batas Otsu

Metode Otsu diterapkan untuk mengelompokkan piksel retakan dan latar belakang secara otomatis berdasarkan distribusi histogram citra. Algoritma ini mencari nilai ambang optimal t^* yang memaksimalkan varians antar-kelas $\sigma_B^2(t)$:

$$\sigma_B^2(t) = \omega_0(t)(\mu_0(t) - \mu_T)^2 + \omega_1(t)(\mu_1(t) - \mu_T)^2 \quad (4)$$

dengan t adalah nilai intensitas ambang batas uji; $\omega_0(t)$ dan $\omega_1(t)$ adalah probabilitas kumulatif untuk kelas latar belakang dan kelas objek retakan pada

ambang t ; $\mu_0(t)$ dan $\mu_1(t)$ adalah nilai rata-rata intensitas piksel masing-masing kelas pada ambang t ; μ_T dan adalah nilai rata-rata intensitas keseluruhan citra I_{enhanced} . Selanjutnya, binerisasi dilakukan untuk membentuk masker biner $M_{\text{Otsu}}(x, y)$:

$$M_{\text{Otsu}}(x, y) = \begin{cases} 1, & \text{jika } I_{\text{enhanced}}(x, y) \geq t^* \\ 0, & \text{jika } I_{\text{enhanced}}(x, y) < t^* \end{cases} \quad (5)$$

2. Segmentasi Berbasis Gradien dengan Canny

Batas struktur fisik retakan dideteksi melalui diskontinuitas lokal menggunakan operator Canny pada citra $I_{\text{enhanced}}(x, y)$. Magnitudo gradien $G(x, y)$ dan orientasi gradien $\theta(x, y)$ dihitung menggunakan turunan parsial horizontal $G_x(x, y)$ dan vertikal $G_y(x, y)$:

$$G(x, y) = \sqrt{G_x(x, y)^2 + G_y(x, y)^2} \quad (6)$$

$$\theta(x, y) = \arctan \left(\frac{G_y(x, y)}{G_x(x, y)} \right) \quad (7)$$

Piksel gradien kemudian ditipiskan melalui penekanan nonmaksimum sepanjang arah $\theta(x, y)$, dilanjutkan dengan pembatasan menggunakan ambang ganda untuk membentuk citra tepi biner $M_{\text{Canny}}(x, y) \in \{0, 1\}$. Piksel bernilai 1 merepresentasikan batas luar retakan serta sisa derau lokal yang memiliki kontras tinggi.

3. Fusi Spasial

Garis kontur Canny berada pada batas gradien terluar, sedangkan masker Otsu melingkupi area badan retakan. Untuk mencegah terputusnya kontur Canny akibat pergeseran batas spasial, masker M_{Otsu} diperluas melalui operasi morfologi dilatasi dengan *structuring element* B :

$$M_{\text{Otsu}}^{\text{dil}}(x, y) = (M_{\text{Otsu}} \oplus B)(x, y) = \max_{z \in B} M_{\text{Otsu}}(x - z, y) \quad (8)$$

dengan $\oplus$ melambangkan operator dilatasi morfologi, B adalah matriks biner *structuring element* yang memberikan toleransi spasial di sekitar kontur retakan, dan $\max_{z \in B}$ merupakan operator yang mengambil nilai piksel tertinggi di dalam jangkauan jendela B . Selanjutnya, fusi spasial dilakukan melalui operasi logika biner irisan (Logical AND):

$$M_{\text{fusi}}(x, y) = M_{\text{Canny}}(x, y) \wedge M_{\text{Otsu}}^{\text{dil}}(x, y) \quad (9)$$

Melalui fusi ini, tepi Canny hanya dipertahankan apabila berada di dalam wilayah terang hasil *thresholding* Otsu. Sebagai tahap akhir, dilakukan pembersihan artefak menggunakan analisis komponen terhubung (*connected component analysis*). Komponen biner yang memiliki luas area di bawah ambang batas minimum τ_{area} dieliminasi dengan rumus:

$$M_{\text{final}} = \bigcup \{C_k \subset M_{\text{fusi}} \mid \text{Area}(C_k) \geq \tau_{\text{area}}\} \quad (10)$$

dengan $\bigcup$ merupakan operator gabungan himpunan, C_k merupakan komponen terhubung ke- k pada citra biner M_{fusi} , $\text{Area}(C_k)$ adalah jumlah piksel penyusun komponen C_k , dan τ_{area} adalah nilai ambang luas minimum untuk menyaring derau terisolasi.

D. Ekstraksi Fitur

Tahap ekstraksi fitur bertujuan memetakan informasi visual pada citra menjadi sekumpulan deskriptor numerik yang memiliki daya diskriminasi tinggi untuk mengklasifikasikan tiga jenis keretakan jalan. Ekstraksi fitur dilakukan secara komplementer pada dua representasi data, yaitu citra derajat keabuan hasil peningkatan kualitas (I_{enhanced}) dan masker biner hasil segmentasi (M_{final}).

1. Fitur Tekstur Statistik dengan *Gray-Level Co-occurrence Matrix* (GLCM)

GLCM memodelkan hubungan spasial antarpiksel dengan menghitung matriks probabilitas transisi $P(i, j \mid d, \theta)$, yaitu frekuensi kemunculan piksel bernilai intensitas i yang berdampingan dengan piksel bernilai j pada jarak perpindahan d dan orientasi arah θ .

Ekstraksi diterapkan pada citra intensitas I_{enhanced} . Untuk efisiensi komputasi dan kestabilan probabilitas, tingkat keabuan dikuantisasi ke dalam $N_g = 32$ level. Nilai jarak perpindahan ditetapkan sebesar $d = 1$ piksel guna menangkap variasi batas mikroskopis. Matriks GLCM dihitung secara terpisah pada empat arah sudut spasial $\theta \in \{0^\circ, 45^\circ, 90^\circ, 135^\circ\}$.

Pada setiap sudut, diekstraksi empat parameter statistik. Pertama, kontras yang merepresentasikan intensitas perbedaan atau variasi derajat keabuan lokal antara pasangan piksel yang saling bertetangga. Kedua, homogenitas yang mengukur tingkat keseragaman lokal atau seberapa rapat persebaran pasangan piksel di sekitar diagonal utama matriks probabilitas. Ketiga, energi yang mengukur derajat keteraturan, repetisi tekstur, dan keseragaman distribusi probabilitas pasangan intensitas pada citra. Kemudian, keempat, mengukur tingkat ketergantungan linier nilai derajat keabuan antarpiksel tetangga sepanjang arah orientasi yang diamati. Kombinasi empat parameter statistik pada empat orientasi sudut tersebut menghasilkan total 16 fitur skalar tekstur GLCM.

Penerapan GLCM pada empat arah orientasi spasial bertujuan untuk menangkap perbedaan respons tekstur saat hubungan antarpiksel ditelusuri searah maupun menyilang jalur retakan pada bidang citra dua dimensi. Penelusuran piksel yang sejajar dengan alur retakan menghasilkan perubahan intensitas yang mulus (kontras rendah dan korelasi tinggi). Sebaliknya, penelusuran yang memotong alur retakan secara melintang memicu lonjakan perbedaan intensitas yang tajam antara garis retakan dan permukaan aspal (kontras tinggi). Ketimpangan nilai statistik antarsudut ini menjadi kunci untuk membedakan jenis keretakan. Dengan mempertahankan evaluasi di empat sudut terpisah, informasi arah yang krusial untuk mengenali orientasi dan pola keretakan dapat terjaga.

2. Fitur Tekstur Lokal Berbasis dengan *Block-based Local Binary Pattern* (Block-LBP)

Ekstraksi Block-LBP mengintegrasikan analisis pola mikro lokal dengan distribusi spasial makro. Citra masukan I_{enhanced} dipartisi ke dalam kisi spasial yang tidak tumpang tindih berukuran seragam sebanyak $k \times k$ blok. Setiap sub-blok didefinisikan sebagai $B_{r,c}$, dengan indeks baris $r \in \{1, 2, \dots, k\}$ dan indeks kolom $c \in \{1, 2, \dots, k\}$. Pada setiap piksel pusat (x_c, y_c) di dalam, operator LBP

mengevaluasi perbedaan intensitas terhadap P piksel tetangga yang terletak pada lintasan lingkaran berjari-jari R :

$$LBP_{P,R}(x_c, y_c) = \sum_{p=0}^{P-1} s(g_p - g_c) \cdot 2^p, \quad s(x) = \begin{cases} 1, & x \geq 0 \\ 0, & x < 0 \end{cases} \quad (11)$$

dengan g_c adalah intensitas derajat keabuan pada piksel pusat (x_c, y_c) , g_p adalah intensitas derajat keabuan piksel tetangga ke- p , dan $s(x)$ adalah fungsi *step function*.

Selanjutnya, dihitung frekuensi kemunculan pola seragam pada masing-masing ke dalam histogram sepuluh bin dan dinormalisasi menjadi vektor histogram ternormalisasi berdimensi sepuluh dari baris ke- r dan kolom ke- c $\mathbf{h}_{r,c} \in \mathbb{R}^{59}$. Seluruh histogram sub-blok tersebut kemudian digabungkan secara sekuensial (feature concatenation) menjadi satu vektor fitur global akhir $\mathbf{v}_{\text{Block-LBP}} = [\mathbf{h}_{1,1}^T \quad \mathbf{h}_{1,2}^T \quad \dots \quad \mathbf{h}_{k,k}^T]^T \in \mathbb{R}^{k^2 \times 59}$.

Fitur ini diekstraksi untuk mengintegrasikan pengenalan tekstur mikro lokal dengan informasi distribusi spasial retakan di atas bidang citra. Pola retakan garis tunggal cenderung mengonsentrasikan respons tekstur hanya pada jajaran sub-blok tertentu (searah sumbu vertikal atau horizontal), sedangkan retakan berpola jaring menghasilkan respons tekstur yang tersebar merata di seluruh. Dengan demikian, variasi sebaran tekstur antar ini memberikan representasi spasial yang efektif untuk membedakan orientasi dan kepadatan pola keretakan jalan.

3. Fitur Orientasi Garis dengan *Probabilistic Hough Transform*

Probabilistic Hough Transform diterapkan pada kontur tepi masker segmentasi M_{final} dengan memproyeksikan sampel acak piksel tepi ke ruang akumulator parameter polar melalui persamaan normal:

$$\rho = x \cos \theta + y \sin \theta \quad (12)$$

dengan ρ menyatakan jarak tegak lurus dari titik asal ke garis dan θ menyatakan sudut normal garis. Ketika akumulasi suara pada sel parameter melampaui nilai ambang batas, algoritma menelusuri kontinuitas deretan piksel di sepanjang lintasan garis dengan batas toleransi celah tertentu. Deretan piksel yang memenuhi syarat

panjang minimum divalidasi sebagai satu segmen garis berhingga dengan mencatat koordinat titik awal $(x_{1,m}, y_{1,m})$ dan titik akhir $(x_{2,m}, y_{2,m})$.

Proses penelusuran tersebut menghasilkan himpunan M buah segmen garis diskret:

$$\mathcal{L} = \left\{ \left((x_{1,m}, y_{1,m}), (x_{2,m}, y_{2,m}) \right) \mid m = 1, 2, \dots, M \right\} \quad (13)$$

Untuk setiap segmen ke- m , panjang segmen l_m dan sudut kemiringan $\phi_m \in [0^\circ, 180^\circ]$ dihitung melalui:

$$l_m = \sqrt{(x_{2,m} - x_{1,m})^2 + (y_{2,m} - y_{1,m})^2} \quad (14)$$

$$\phi_m = \left| \arctan \left(\frac{y_{2,m} - y_{1,m}}{x_{2,m} - x_{1,m}} \right) \right| \times \frac{180^\circ}{\pi} \quad (15)$$

Dari akumulasi seluruh segmen garis yang terdeteksi, diekstraksi tiga fitur skalar: sudut dominan terbobot yang merupakan rata-rata sudut orientasi garis yang dibobotkan oleh panjang masing-masing segmen; rasio arah spasial yang merupakan perbandingan akumulasi panjang segmen garis berorientasi vertikal terhadap segmen garis berorientasi horizontal; dan jumlah segmen garis yang merepresentasikan kuantitas total segmen linier diskrit yang terdeteksi pada bidang citra.

Penerapan PHT ini relevan karena retakan jalan di dunia nyata dapat berbentuk patahan-patahan segmen linier yang berliku. PHT secara efektif mendeteksi orientasi lokal dari segmen-segmen pendek tersebut tanpa memaksakan kecocokan garis tunggal. Fitur sudut dominan dan rasio arah yang dihasilkan memberikan deskriptor geometris yang jelas untuk membedakan retakan yang memiliki kecenderungan arah lintasan tertentu dari retakan yang berorientasi acak atau menyebar multiarah.

4. Fitur Morfologi dan Topologi

Fitur morfologi dan topologi diekstraksi dari masker biner M_{final} berukuran $H \times W$ piksel untuk mengukur bentuk dan struktur konektivitas pola retakan. Piksel retakan yang saling bertetangga (konektivitas 8 arah) dikelompokkan menjadi C komponen terhubung $\{R_k\}_{k=1}^C$. Setiap komponen R_k dicirikan oleh luas A_k yang menyatakan jumlah pikselnya, serta oleh elips yang memiliki momen kedua

sama dengan komponen tersebut. Dari elips ini diperoleh rasio aspek $\rho_k = L_k^{\text{maj}}/L_k^{\text{min}}$, dengan L_k^{maj} dan L_k^{min} berturut-turut panjang sumbu mayor dan sumbu minor, serta eksentrisitas $e_k = \sqrt{1 - (L_k^{\text{min}}/L_k^{\text{maj}})^2}$. Dua deskriptor lain adalah solidity $s_k = A_k/A_k^{\text{hull}}$, yaitu rasio luas komponen terhadap luas selubung cembungnya, dan extent $x_k = A_k/A_k^{\text{bbox}}$, yaitu rasio luas komponen terhadap luas kotak pembatasnya. Proporsi retakan terhadap seluruh citra dinyatakan sebagai rasio luas:

$$r_A = \frac{A_{\text{tot}}}{H \times W}, \quad A_{\text{tot}} = \sum_{k=1}^C A_k, \quad (16)$$

sedangkan nilai A_k , ρ_k , dan e_k diringkas menjadi rata-rata dan simpangan baku antarkomponen, dan s_k serta x_k diringkas menjadi rata-ratanya saja.

Struktur topologi dianalisis dari citra rangka $S(x, y) \in \{0, 1\}$, yaitu hasil penipisan M_{final} menjadi garis selebar satu piksel. Panjang rangka didefinisikan sebagai $\ell_S = \sum_{x,y} S(x, y)$, dan nisbahnya terhadap luas retakan, ℓ_S/A_{tot} , mengukur seberapa memanjang retakan relatif terhadap ketebalannya. Untuk setiap piksel rangka p , jumlah tetangga rangka pada lingkungan 8 piksel dinyatakan sebagai $N(p)$. Piksel dengan $N(p) \geq 3$ dikategorikan sebagai titik percabangan dan piksel dengan $N(p) = 1$ sebagai titik ujung, sehingga kerapatan keduanya dihitung sebagai:

$$\delta_B = \frac{|\{p \in S : N(p) \geq 3\}|}{\ell_S + \epsilon}, \quad \delta_E = \frac{|\{p \in S : N(p) = 1\}|}{\ell_S + \epsilon}, \quad (17)$$

dengan ϵ bilangan kecil yang mencegah pembagian dengan nol. Terakhir, bilangan Euler $E = C - O$ pada M_{final} , dengan O jumlah rongga tertutup di dalam pola retakan, dinormalisasi menjadi $E/(\ell_S + \epsilon)$ agar tidak bergantung pada ukuran retakan. Apabila tidak ada komponen yang terdeteksi, seluruh fitur bernilai nol. Keenam belas fitur, yaitu C , r_A , empat statistik luas dan rasio aspek, empat statistik

eksentrisitas, solidity, dan extent, ℓ_S , ℓ_S/A_{tot} , δ_B , δ_E , E , dan $E/(\ell_S + \epsilon)$, disusun menjadi vektor $\mathbf{v}_{\text{Morf}} \in \mathbb{R}^{16}$.

Fitur ini relevan karena tiap jenis retakan berbeda dalam bentuk dan konektivitasnya. Retakan longitudinal dan transversal umumnya berupa satu atau sedikit komponen memanjang dengan ρ_k dan e_k tinggi, δ_B rendah, serta hampir tanpa rongga tertutup. Sebaliknya, alligator crack membentuk jejaring poligon yang saling terhubung, sehingga menghasilkan r_A , ℓ_S , dan δ_B yang lebih besar serta nilai E yang menurun akibat banyaknya rongga tertutup.

E. Representasi Fitur

Tahap representasi fitur bertujuan mengintegrasikan seluruh deskriptor numerik hasil ekstraksi ke dalam satu ruang vektor terpadu untuk menyelaraskan skala antardeskriptor sebelum digunakan untuk tahap klasifikasi.

1. Penggabungan Vektor Fitur

Seluruh fitur yang diperoleh dari empat kelompok ekstraksi, yakni tekstur statistik GLCM ($\mathbf{v}_{\text{GLCM}} \in \mathbb{R}^{16}$), tekstur spasial lokal Block-LBP ($\mathbf{v}_{\text{Block-LBP}} \in \mathbb{R}^{k^2 \times 59}$), dan morfologi-topologi ($\mathbf{v}_{\text{Morf}} \in \mathbb{R}^{16}$), digabungkan secara sekuensial (*feature concatenation*) untuk membentuk satu vektor fitur global $\mathbf{x} \in \mathbb{R}^D$:

$$\mathbf{x} = [\mathbf{v}_{\text{GLCM}}^T \parallel \mathbf{v}_{\text{Block-LBP}}^T \parallel \mathbf{v}_{\text{PHT}}^T \parallel \mathbf{v}_{\text{Morf}}^T]^T \quad (18)$$

2. Standardisasi Fitur

Karena setiap fitur memiliki satuan dan skala magnitudo yang sangat bervariasi, dilakukan standardisasi skala menggunakan metode Z-score. Untuk setiap elemen fitur ke- j pada sampel data ke- i :

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j} \quad (19)$$

dengan x_{ij} adalah nilai fitur mentah ke- j pada sampel citra ke- i , μ_j adalah rata-rata nilai fitur ke- j di seluruh dataset latih berukuran N , σ_j adalah simpangan

baku fitur ke- j , dan z_{ij} adalah nilai fitur terstandarisasi dengan rata-rata 0 dan varians 1. Parameter μ_j dan σ_j dihitung secara eksklusif hanya pada data latih, kemudian diterapkan langsung ke data uji untuk mencegah kebocoran informasi.

F. Klasifikasi Menggunakan *Machine Learning*

Tahap klasifikasi bertujuan memetakan vektor representasi fitur akhir ke dalam salah satu dari tiga label kelas target, yakni *longitudinal crack*, *transverse crack*, atau *alligator crack*. Proyek ini membandingkan dua algoritma pembelajaran mesin berbasis tabular dengan paradigma yang berbeda, yakni *Support Vector Machine* (SVM) yang berbasis pemisahan bidang berskala margin maksimum dan *Extreme Gradient Boosting* (XGBoost) yang berbasis ansambel pohon keputusan.

SVM mengidentifikasi bidang batas pemisah (*optimal hyperplane*) yang memaksimalkan jarak pemisah antarkelas sekaligus meminimalkan kesalahan klasifikasi melalui formulasi optimasi *soft-margin*. Pemilihan SVM didasari oleh efektivitas matematisnya dalam memproses representasi fitur menggunakan prinsip margin pemisah maksimal.

Sementara itu, XGBoost membangun *ensemble* pohon keputusan secara bertahap (*gradient boosting*) dengan meminimalkan fungsi objektif regularisasi terbobot. Prediksi akhir merupakan jumlahan kontribusi dari beberapa buah pohon regresi klasifikasi. Model ini dipilih karena kemampuannya dalam membangun struktur percabangan pohon yang dalam dan stabil tanpa mengalami *overfitting* serta menangani ketimpangan jumlah data secara adaptif melalui pembobotan gradien partisi daun untuk menghasilkan performa klasifikasi yang stabil dan presisi tinggi.

Hasil klasifikasi selanjutnya diuji dengan metrik *F1 score* yang dihitung dari *confusion matrix* pada data uji. Untuk setiap kelas $c \in \{\textit{alligator}, \textit{longitudinal}, \textit{transverse}\}$, dihitung terlebih dahulu *precision* dan *recall*, sebagai berikut :

$$\text{Precision} = \frac{TP_c}{TP_c + FP_c} \quad (20)$$

$$\text{Precision} = \frac{TP_c}{TP_c + FN_c} \quad (21)$$

dengan TP_c (*true positive*) adalah jumlah citra kelas c yang diprediksi benar sebagai kelas c , FP_c (*false positive*) adalah jumlah citra bukan kelas c yang keliru diprediksi sebagai kelas c , dan FN_c (*false negative*) adalah jumlah citra kelas c yang keliru diprediksi sebagai kelas lain. F1 *score* per kelas merupakan rata-rata harmonik dari *precision* dan *recall*, sebagai berikut:

$$F1_c = \frac{2 \times \text{Precision}_c \times \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c} \quad (22)$$

Karena penelitian ini melibatkan tiga kelas, performa keseluruhan model dinyatakan menggunakan *macro-averaged* F1 *score*, yaitu rata-rata aritmetika F1 *score* dari seluruh kelas, sebagai berikut :

$$F1_{\text{macro}} = \frac{1}{C} \sum_{c=1}^C F1_c \quad (23)$$

dengan $C = 3$ sebagai jumlah kelas.

Metrik F1 *score* dipilih karena mempertimbangkan *precision* dan *recall* sekaligus, sehingga lebih informatif dibandingkan akurasi ketika distribusi kelas tidak seimbang. Pada data uji, jumlah citra *alligator crack* (210) hampir separuh dari *longitudinal crack* (391), sehingga akurasi berpotensi didominasi oleh kelas mayoritas. Penggunaan *macro-averaging* memberikan bobot yang sama pada setiap kelas sehingga performa pada kelas minoritas tetap tercermin. Selain nilai *macro* F1, F1 *score* per kelas juga dilaporkan untuk mengetahui jenis retakan mana yang paling sulit dibedakan oleh masing-masing algoritma. Data validasi digunakan untuk penyetelan hiperparameter, sedangkan data uji hanya digunakan pada evaluasi akhir.

DAFTAR PUSTAKA

- Zain, M. M. (2024). Optimalisasi kerusakan jalan di Indonesia melalui aplikasi pelaporan dan pendeteksi kerusakan jalan. *Jurnal Elektro dan Mesin Terapan*, 10(1), 54–64. <https://doi.org/10.35143/elementer.v10i1.6300>
- Chatterjee, R., Chatterjee, A., Roy, S., & Gourisaria, M. K. (2022). A fast and effective machine learning approach for road cracks classification. In 2022 IEEE 19th India Council International Conference (INDICON) (pp. 1–6). IEEE. <https://doi.org/10.1109/INDICON56171.2022.10039911>
- Chen, C., Seo, H., Jun, C. H., & Zhao, Y. (2022). Pavement crack detection and classification based on fusion feature of LBP and PCA with SVM. *International Journal of Pavement Engineering*, 23(9), 3274–3283. <https://doi.org/10.1080/10298436.2021.1888092>
- Ha, J., Kim, D. & Kim, M. (2022). Assessing severity of road cracks using deep learning-based segmentation and detection. *J Supercomput* 78, 17721–17735. <https://doi.org/10.1007/s11227-022-04560-x>
- Hoang, N.-D., & Nguyen, Q.-L. (2019). A novel method for asphalt pavement crack classification based on image processing and machine learning. *Engineering with Computers*, 35(2), 487–498. <https://doi.org/10.1007/s00366-018-0611-9>
- Li, D., Che, Z., Zhang, H., Zhou, D., Zhang, Z., & Han, Y. (2026). PaveBench: A versatile benchmark for pavement distress perception and interactive vision-language analysis. arXiv. <https://doi.org/10.48550/arXiv.2604.02804>
- Liang, C., Zhao, C., & Liu, Y. (2025). Mechanism of longitudinal cracking in concrete deck slabs of composite cable-stayed bridges. *Engineering Structures*, 327, Artikel 119544. <https://doi.org/10.1016/j.engstruct.2024.119544>
- Sari, Y., Prakoso, P. B., & Baskara, A. R. (2019). Road crack detection using Support Vector Machine (SVM) and OTSU algorithm. In 2019 6th International Conference on Electric Vehicular Technology (ICEVT) (pp. 349–354). IEEE. doi: 10.1109/ICEVT48285.2019.8993969
- Li, D., Che, Z., Zhang, H., Zhou, D., Zhang, Z., & Han, Y. (2026) [Dataset]. PaveBench: A versatile benchmark for pavement distress perception and interactive vision-language analysis. arXiv. <https://doi.org/10.48550/arXiv.2604.02804>

wzhen@vt.edu. (2022). *Pavement cracks Dataset* [Dataset]. Roboflow Universe.
<https://universe.roboflow.com/wzhen-vt-edu/pavement-cracks-2wi3m>